Detección de fraude mediante Redes Neuronales Bayesianas: decisiones bajo incertidumbre

Antonio Lorenzo Díaz Meco y Javier Ríos Montes
Proyecto Final — Inteligencia Artificial Probabilística

Abstract

Este trabajo desarrolla un enfoque que combina modelos deterministas con una red neuronal bayesiana para transformar probabilidades predictivas en una política de triaje operativo (ACCEPT, REVIEW, BLOCK), todo ello en el contexto de detección de fraude con tarjetas de crédito.

El sistema estima tanto la probabilidad de fraude como la incertidumbre predictiva, y utiliza esta última para implementar predicción selectiva y control de cobertura-riesgo. Los resultados muestran que, aunque los modelos basados en árboles dominan en rendimiento predictivo y calibración, la red bayesiana permite identificar regiones de alta incertidumbre donde la automatización es menos fiable y, con un umbral de incertidumbre ajustado *post hoc*, aceptar automáticamente una fracción sustancial de transacciones manteniendo un fraude residual extremadamente bajo en el bucket ACCEPT.

Estos resultados sugieren que el valor del modelado probabilístico en este contexto no está en mejorar métricas de clasificación, sino en habilitar decisiones más seguras mediante abstención selectiva y asignación adaptativa de recursos.

1. Introducción

La detección de fraude con tarjetas de crédito es un problema altamente desbalanceado en el que el rendimiento predictivo no es suficiente para garantizar decisiones fiables. En entornos reales, los sistemas automáticos deben decidir no solo si una transacción es fraudulenta, sino también cuándo esa decisión puede automatizarse con seguridad. En particular, es necesario distinguir entre operaciones que pueden aceptarse automáticamente, casos que requieren revisión humana y situaciones donde conviene bloquear directamente. Este planteamiento conecta con modelos probabilísticos, calibración y clasificación selectiva [3, 6, 10].

Sin embargo, la mayoría de enfoques en fraude tabular se centran en optimizar métricas de discriminación, ignorando el papel de la incertidumbre en la toma de decisiones. En contextos sensibles al riesgo, esta limitación es crítica, ya que no todos los errores tienen el mismo coste. En este sentido, los modelos bayesianos resultan especialmente atractivos, ya que permiten estimar incertidumbre predictiva además de probabilidades.

En este trabajo proponemos un enfoque basado en incertidumbre que combina baselines deterministas con una red neuronal bayesiana (BNN). El sistema estima probabilidad de fraude e incertidumbre y las integra en una política de triaje con tres acciones: ACCEPT, REVIEW y BLOCK. Este diseño permite implementar predicción selectiva y analizar explícitamente el compromiso cobertura-riesgo.

En última instancia, este proyecto no sólo busca comparar modelos de detección de fraude, sino explorar cómo no existe una regla universal mediante la cual juzgar nuestros modelos (p.ej., PR-AUC ó NLL), sino que la utilidad de cada modelo depende de cómo se traduzca su salida en decisiones operativas. En este sentido, el valor de un modelo bayesiano no procederá, necesariamente, de superar a los modelos tabulares en clasificación pura, sino de hacer visible qué parte del espacio de decisión debería tratarse con mayor cautela.

Contribuciones.

- Proponemos un enfoque de detección de fraude basado en incertidumbre que integra predicción y decisión operativa.
- Comparamos una BNN con baselines deterministas, evaluando tanto rendimiento predictivo como utilidad decisional.
- Introducimos una política de triaje (ACCEPT/REVIEW/BLOCK) basada en probabilidad e incertidumbre, junto con análisis de predicción selectiva.
- Mostramos que el umbral de incertidumbre no es un hiperparámetro fijo arbitrario, sino una palanca operativa que puede ajustarse para equilibrar automatización y riesgo residual.

2. Método

2.1. Planteamiento del problema

Sea $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{N}$, con $x_i \in \mathbb{R}^d$ e $y_i \in \{0, 1\}$, donde $y_i = 1$ indica fraude. El objetivo no es solo estimar $p(y_i = 1 \mid x_i, \mathcal{D})$ (es decir, la probabilidad de que una transacción con ciertas características sea fraudulenta), sino producir además una señal de incertidumbre y traducir ambas cantidades en una acción operativa $a_i \in \{\text{ACCEPT}, \text{REVIEW}, \text{BLOCK}\}$.

Desde el punto de vista funcional, el sistema debe emitir probabilidades predictivas, cuantificar incertidumbre a nivel de muestra y permitir inspección interactiva de casos. Desde el punto de vista no funcional, debe ser reproducible, medible en latencia de inferencia y evaluable con métricas probabilísticas adecuadas. El interés de este planteamiento es operativo: en fraude, un falso negativo puede ser costoso, mientras que una revisión humana tiene un coste intermedio. Por tanto, la cuestión relevante no es únicamente qué modelo clasifica mejor, sino cuál permite tomar decisiones más seguras bajo incertidumbre (evitar, en la medida de lo posible, dedicar recursos humanos a casos de bajo riesgo o automatizar casos de alto riesgo).

2.2. Bayesian neural network

Las redes neuronales bayesianas permiten modelar incertidumbre sobre los pesos y, por extensión, sobre las predicciones. *Bayes by Backprop* aproximó este problema mediante inferencia variacional y optimización del ELBO [1, 8]. Aunque MC dropout también puede interpretarse como una aproximación bayesiana [4], en este proyecto el *dropout* se desactiva para que la incertidumbre proceda únicamente del posterior variacional sobre los pesos. La implementación probabilística se apoya en Pyro [11–13].

La BNN es un MLP bayesiano con dos capas ocultas:

$$f_w(x) = W_3\, \phi(W_2\, \phi(W_1 x + b_1) + b_2) + b_3,$$

donde $\phi(\cdot)$ es la activación SiLU [1]. El vector completo de parámetros se denota por $w = \{W_1, b_1, W_2, b_2, W_3, b_3\}$.

Sobre cada bloque de pesos y sesgos se definen priors gaussianos independientes con escala

$$p(w) = \prod_j \mathcal{N}(w_j; 0, \sigma_p^2), \qquad \sigma_p = 0.9.$$

La verosimilitud binaria se modela mediante logits:

$$p(y_i \mid x_i, w) = \text{Bernoulli}(y_i; \sigma(f_w(x_i)))\,,$$

o equivalentemente

$$y_i \sim \text{Bernoulli}(\text{logits} = f_w(x_i))\,.$$

[1] La función SiLU (Sigmoid Linear Unit) es definida como $\phi(x) = x \cdot \sigma(x)$, donde $\sigma(x)$ es la función sigmoide. Es ventajosa, respecto a otras alternativas como ReLU, gracias a que *produce* gradientes más suaves y evita *neuronas muertas*

La posterior exacta es

$$p(w \mid \mathcal{D}) \propto p(w) \prod_{i=1}^{N} p(y_i \mid x_i, w),$$

que es intratable para una red no lineal.

2.3. Inferencia variacional

El entrenamiento usa `SVI` con `Trace_ELBO` y una guía `AutoDiagonalNormal`. Aproximamos la posterior mediante una familia de campo medio (MFA-VI):

$$q_\phi(w) = \mathcal{N}\big(w; \mu, \mathrm{diag}(s^2)\big),$$

donde $\phi = \{\mu, s\}$ son los parámetros variacionales.

El objetivo es maximizar el ELBO

$$\mathcal{L}(\phi) = \mathbb{E}_{q_\phi(w)} \left[\sum_{i=1}^{N} \log p(y_i \mid x_i, w) \right] - \mathrm{KL}(q_\phi(w) \,\|\, p(w)) \,.$$

Equivalentemente, se minimiza $-\mathcal{L}(\phi)$. Con minibatches $\mathcal{B}$ de tamaño M, Pyro optimiza una estimación estocástica

$$\widehat{\mathcal{L}}(\phi) = \frac{N}{M} \sum_{i \in \mathcal{B}} \mathbb{E}_{q_\phi(w)} \big[\log p(y_i \mid x_i, w) \big] - \mathrm{KL}(q_\phi(w) \,\|\, p(w)) \,,$$

empleando muestreo reparametrizado en la práctica [1, 8].

2.4. Distribución predictiva, incertidumbre y regla de decisión

Para un nuevo ejemplo $x^\star$, la probabilidad predictiva bayesiana ideal es

$$p(y^\star = 1 \mid x^\star, \mathcal{D}) = \int \sigma(f_w(x^\star))\, p(w \mid \mathcal{D})\, dw.$$

Sin embargo, como la posterior $p(w \mid \mathcal{D})$ es intratable, se aproxima mediante $q_\phi(w)$. Por tanto, la probabilidad predictiva aproximada se estima mediante muestreo Monte Carlo:

$$\hat{p}(x^\star) = \frac{1}{S} \sum_{s=1}^{S} \sigma(f_{w^{(s)}}(x^\star)) \,, \qquad w^{(s)} \sim q_\phi(w).$$

Mediante dichas muestras, se establece una señal de incertidumbre basada en la desviación estándar de las probabilidades inducidas por distintas muestras del posterior:

$$u(x^\star) = \sqrt{\frac{1}{S-1} \sum_{s=1}^{S} \big(\sigma(f_{w^{(s)}}(x^\star)) - \hat{p}(x^\star)\big)^2}.$$

En nuestro caso, la incertidumbre no se descompone explícitamente en parte aleatoria y parte epistémica. Usamos en su lugar la desviación estándar de las probabilidades de fraude obtenidas a partir de distintas muestras del posterior sobre los pesos. Una desviación alta indica que el modelo da respuestas muy diferentes para la misma transacción, es decir, que su predicción es inestable.

Para decidir qué transacciones derivar a revisión necesitamos fijar un umbral τ sobre la probabilidad de fraude. En lugar de usar un umbral arbitrario (p.ej., $\tau = 0.5$), seleccionamos $\tau^\star$ maximizando la métrica F1 en el conjunto de validación:

$$\tau^\star = \arg \max_{\tau \in [0,1]} \mathrm{F1}\big(y, \mathbb{I}[\hat{p}(x) \geq \tau]\big),$$

y reutilizamos es mismo umbral en test, evitando *test leakage* y permitiendo fijar un punto de operación comparable entre modelos. En el caso de la BNN, el umbral validado es, aproximadamente, $\tau^\star_{\mathrm{BNN}} \approx 0.90$. [2]

[2] Como detallamos en la sección posterior, dicho umbral es específico para la BNN, ya que cada modelo tiene una curva de precisión-recall diferente. Por tanto, cada modelo tiene su propio umbral validado.

Sea $\hat{p}(x)$ la probabilidad de fraude estimada por la BNN y $u(x)$ la incertidumbre. La política implementada se formaliza como

$$d(x) = \begin{cases} \text{BLOCK}, & \hat{p}(x) \geq \tau_{\text{block}} \text{ AND } u(x) \leq \tau_u, \\ \text{REVIEW}, & \hat{p}(x) \geq \tau^\star \text{ OR } u(x) > \tau_u, \\ \text{ACCEPT}, & \text{en otro caso}, \end{cases}$$

con $\tau_{\text{block}} = 0.80, \qquad \tau_u = 0.1857 \approx 0.186.$

Para un umbral de abstención λ sobre la incertidumbre, definimos el subconjunto retenido $S_\lambda = \{i : u_i \leq \lambda\}$. La cobertura es

$$C(\lambda) = \frac{|S_\lambda|}{N},$$

y el riesgo empírico sobre los ejemplos retenidos es

$$R(\lambda) = \frac{1}{|S_\lambda|} \sum_{i \in S_\lambda} \mathbb{I}[\hat{y}_i \neq y_i].$$

La precisión selectiva se resume por

$$A(\lambda) = 1 - R(\lambda).$$

Esta formulación se alinea con la literatura de clasificación selectiva [3]. En resumen, el modelo no solo produce una predicción probabilística, sino que convierte dicha predicción en una política explícita de automatización parcial.

2.5. Selección del umbral de incertidumbre

A diferencia del umbral de probabilidad, que se valida en el conjunto de validación maximizando F1, el umbral de incertidumbre τ_u controla un compromiso diferente: cuánto volumen puede automatizar el sistema sin degradar en exceso la seguridad del bucket ACCEPT. En otras palabras, τ_u no regula discriminación binaria, sino el equilibrio entre cobertura automática y riesgo residual.

Para estudiar este compromiso analizamos, *post hoc*, cómo varían simultáneamente la fracción de transacciones aceptadas automáticamente y la tasa de fraude dentro del bucket ACCEPT al barrer distintos valores de τ_u. La Figura 1 muestra este trade-off. El valor inicial $\tau_u = 0.10$ resultó excesivamente conservador, ya que enviaba más del 72 % de las transacciones a REVIEW. Por ello, seleccionamos un operating point más equilibrado buscando minimizar la tasa de fraude residual en ACCEPT sujeto a una cobertura mínima del 50 %. El valor resultante es $\tau_u \approx 0.186$.

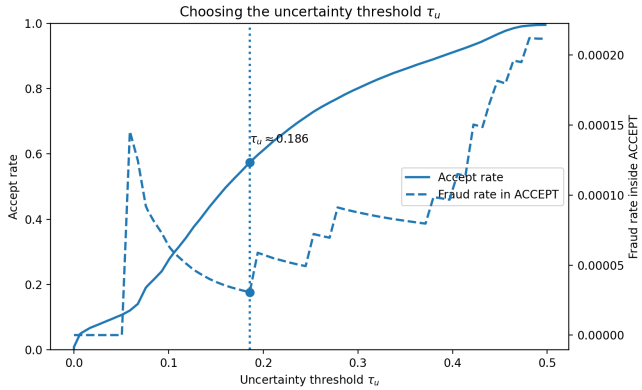

Figura 1: Selección del umbral de incertidumbre τ_u. Al aumentar τ_u, crece la fracción de transacciones aceptadas automáticamente, mientras que la tasa de fraude dentro de ACCEPT se mantiene muy baja en un rango amplio. La línea vertical marca el umbral seleccionado para el sistema final.

3. Configuración experimental

3.1. Datos y preprocesado

Se emplea el dataset público de fraude de tarjetas de crédito de la colaboración Worldline–ULB, ampliamente usado como benchmark de clasificación tabular desbalanceada [2, 7]. Los *splits* son estratificados y corresponden a $60/20/20$ para train, validation y test.

El preprocesado depende de la familia de modelo:

- **Logistic Regression, BNN y GPLVM:** imputación por mediana y `StandardScaler`.
- **Random Forest y XGBoost:** imputación por mediana sin escalado.

El desbalance se trata de forma distinta según el modelo:

- **Logistic Regression y Random Forest:** `class_weight="balanced"`.
- **XGBoost:** `scale_pos_weight = #neg/#pos` calculado sobre train.
- **BNN:** `WeightedRandomSampler` con pesos inversos a la frecuencia de clase.

3.2. Modelos, entrenamiento y protocolo de evaluación

Además de la BNN, comparamos *Logistic Regression*, *Random Forest* y *XGBoost* como baselines deterministas fuertes. A continuación, resumimos los hiperparámetros que más condicionan el comportamiento probabilístico y computacional del sistema, omitiendo parámetros secundarios de implementación para priorizar la interpretación experimental.

Tabla 1: Hiperparámetros principales del sistema.

Componente	Configuración
Splits	60/20/20 (train/validación/test)
Random Forest	300 árboles
XGBoost	300 árboles, profundidad 5, learning rate 0.05
BNN	2 capas ocultas: 256 y 128 unidades; prior scale 0.9
Optimización BNN	learning rate 2×10^{-4}, 150 épocas, batch size 512
Inferencia BNN	100 muestras MC en evaluación; 200 en incertidumbre
Early stopping BNN	paciencia 30 sobre PR-AUC de validación
Decisión	$\tau_{\text{block}} = 0.80$, $\tau_u = 0.186$
GPLVM	dimensión latente 2, 1500 épocas

Como métricas offline usamos PR-AUC, ROC-AUC, F1, NLL, Brier y ECE, ya que cubren discriminación, clasificación puntual y calidad probabilística [5, 6, 10]. Como métricas de negocio identificamos, aunque no desplegamos online en producción, las siguientes: tasa de fraude dentro del bucket BLOCK, fracción de transacciones enviadas a REVIEW, tasa de fraude residual en ACCEPT y latencia de inferencia por muestra.

La Tabla 2 muestra que el sistema no usa un umbral fijo arbitrario, sino un punto de operación validado por F1. Más que el valor exacto de cada umbral, lo relevante es la idea metodológica: cada modelo se evalúa en test con un operating point aprendido en validation, lo que hace comparables las conclusiones.

Tabla 2: Resultados en validación.

Modelo	$\tau^\star$	PR-AUC (%)	ROC-AUC (%)	F1 (%)	Prec. (%)	Rec. (%)	ECE (%)
XGBoost	0.93	82.5	97.5	85.1	93.9	77.8	0.03
Random Forest	0.33	81.2	94.6	82.4	90.4	75.8	0.03
BNN	0.90	67.8	97.4	77.6	76.5	78.8	8.41
Logistic Regression	1.00	68.1	97.5	76.8	82.6	71.7	6.44

4. Resultados y discusión

La Tabla 3 resume el compromiso entre discriminación, clasificación puntual y calidad probabilística. El mensaje importante no es qué modelo logra la mejor cifra aislada, sino qué perfil de comportamiento exhibe cada familia.

Tabla 3: Resultados en test.

Modelo	PR-AUC (%)	ROC-AUC (%)	F1 (%)	Prec. (%)	Rec. (%)	NLL	Brier	ECE (%)
XGBoost	87.0	97.7	85.3	91.8	79.6	0.003	0.0005	0.06
Random Forest	85.1	95.7	86.8	94.1	80.6	0.006	0.0004	0.03
BNN	72.6	97.6	77.1	70.0	85.7	0.107	0.0235	8.32
Logistic Regression	71.8	97.3	80.8	80.0	81.6	0.104	0.0221	6.44

En primer lugar, XGBoost destaca en capacidad de ranking: ordena muy bien los casos por riesgo de fraude. En segundo lugar, Random Forest presenta el perfil más equilibrado entre detección, precisión y fiabilidad probabilística. La BNN, en cambio, no domina en PR-AUC ni en NLL, pero sí muestra un comportamiento interesante para este caso de uso: prioriza recall y, sobre todo, genera una señal de incertidumbre explotable para decisión.

Desde la perspectiva probabilística, esta comparación sugiere que la utilidad de un modelo bayesiano no debe juzgarse solo por métricas de discriminación. Desde la perspectiva aplicada, lo relevante es si esa incertidumbre permite reducir automatizaciones peligrosas y concentrar la revisión humana donde realmente aporta valor. Dicho de otro modo, el resultado principal no es que la BNN "gane" en clasificación pura, sino que desplaza parte del problema desde la predicción hacia la gestión explícita del riesgo de automatización.

La Figura 2 y las métricas de la Tabla 3 muestran que los modelos basados en árboles están mejor calibrados que la BNN sobre este dataset. La diferencia visual entre Random Forest y XGBoost, por un lado, y BNN, por otro, refuerza una conclusión importante: en este proyecto la BNN no aporta su principal valor como estimador calibrado de probabilidades, sino como fuente de incertidumbre para abstención selectiva.

Este punto es importante en términos probabilísticos. Un modelo puede estar relativamente peor calibrado y, aun así, proporcionar una señal de dispersión posterior útil para decisión. En términos operativos, eso significa que calibración y utilidad de triaje no son exactamente la misma propiedad. Un sistema puede no ser el mejor asignando probabilidades calibradas globalmente y, sin embargo, seguir siendo valioso si identifica bien las regiones donde la predicción deja de ser lo bastante estable como para automatizar.

Además, los diagramas sugieren matices entre los propios baselines. Random Forest muestra la figura visualmente más estable, mientras que XGBoost conserva una buena región de alto riesgo aunque con más oscilaciones intermedias. La BNN, por su parte, concentra la mayor desviación respecto a la diagonal ideal, lo que apoya una lectura honesta del experimento: su aportación principal no es calibrar mejor, sino ayudar a decidir cuándo conviene no automatizar.

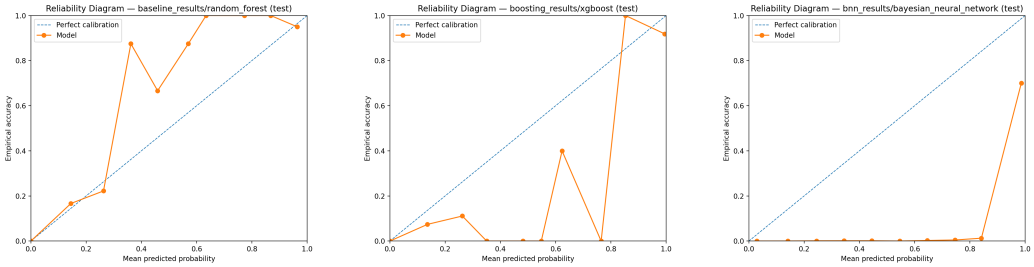

(a) Random Forest (b) XGBoost (c) BNN

Figura 2: Diagramas de fiabilidad en test.

La Tabla 4 resume la transición desde probabilidad e incertidumbre hacia decisiones accionables. A diferencia del operating point inicial con $\tau_u = 0.10$, que era extremadamente conservador, el umbral ajustado $\tau_u \approx 0.186$ permite automatizar una fracción sustancial del flujo manteniendo un fraude residual muy bajo en ACCEPT. ACCEPT concentra transacciones de riesgo muy bajo; BLOCK sigue recogiendo una fracción mínima de operaciones, pero con una tasa de fraude extraordinariamente alta; y REVIEW absorbe la región ambigua donde automatizar resultaría más arriesgado.

Tabla 4: Resumen de decisiones del BNN en test con $\tau_u \approx 0.186$.

Decisión	Conteo	Cobertura (%)	Fraude (%)	Prob. media (%)	Incertidumbre media (%)
ACCEPT	32698	57.4	0.003	1.68	9.90
REVIEW	24167	42.4	0.083	17.49	30.54
BLOCK	97	0.17	79.4	99.68	2.94

Este resultado es central para el caso de uso. Más que producir una etiqueta, el sistema redistribuye el espacio de decisiones en tres niveles de intervención. El bucket BLOCK es especialmente informativo: aunque es muy pequeño, concentra una proporción altísima de fraude y lo hace con incertidumbre media baja, lo que encaja con la idea de bloquear únicamente cuando la predicción es extrema y estable. ACCEPT, por el contrario, recoge ahora más de la mitad del volumen con riesgo residual extremadamente reducido. REVIEW sigue actuando como mecanismo de prudencia, pero deja de absorber casi todo el flujo y pasa a concentrar precisamente los casos donde el riesgo o la inestabilidad posterior desaconsejan una decisión totalmente automática.

La Figura 3 complementa esta lectura mostrando que dichas decisiones se agrupan en regiones diferenciadas del espacio latente. Aunque no existe una separación perfectamente limpia entre las tres clases de decisión, sí aparecen zonas donde REVIEW domina claramente y otras donde ciertos casos BLOCK quedan más apartados. Esto sugiere que la política operativa no es arbitraria, sino que refleja cierta estructura geométrica del espacio inducido por el GPLVM.

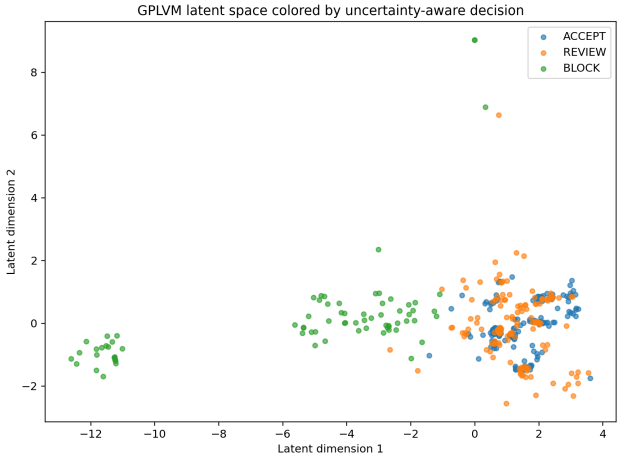

Figura 3: Espacio latente GPLVM coloreado por decisión.

La Figura 4 muestra que la incertidumbre predictiva se concentra en probabilidades intermedias y cae en los extremos cercanos a 0 o 1. Esta estructura es coherente con la interpretación bayesiana del modelo: cuando la posterior predictiva está repartida entre múltiples comportamientos plausibles, la probabilidad media tiende a desplazarse hacia regiones ambiguas y la desviación estándar aumenta.

La forma de arco que aparece en la nube de puntos es especialmente informativa, porque muestra que la incertidumbre no se distribuye al azar. En lugar de eso, aumenta precisamente donde la decisión es menos clara y disminuye cuando la red produce salidas extremas. Esto refuerza la idea de que la incertidumbre puede utilizarse como una señal de segundo nivel para decidir cuánto confiar en la probabilidad predicha.

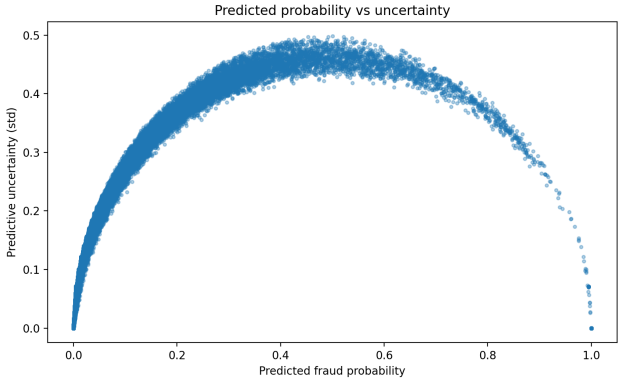

Figura 4: Probabilidad predicha frente a incertidumbre del BNN.

Esta lectura se refuerza con la Figura 6, dispuesta en el Apéndice A.2, que nos ofrece otra perspectiva: los errores más problemáticos tienden a concentrarse en niveles más altos de incertidumbre.

En particular, los falsos negativos aparecen desplazados hacia valores más altos que los verdaderos positivos, lo cual es importante porque el falso negativo es precisamente el error más costoso en este contexto. La figura no implica que la incertidumbre separe perfectamente aciertos y errores, pero sí sugiere que los casos más delicados se concentran en regiones donde la posterior predictiva es menos estable. Desde el punto de vista operativo, esto refuerza la conveniencia de derivar esos casos hacia revisión en lugar de automatizarlos.

La Figura 7 (A.3) formaliza esta idea mediante el análisis riesgo-cobertura. A medida que el sistema restringe la automatización al subconjunto menos incierto, el riesgo empírico disminuye. En consecuencia, la incertidumbre no actúa solo como descriptor estadístico, sino como variable de control para modular la agresividad de la decisión automática.

La caída brusca del riesgo al abandonar las regiones más inciertas sugiere que la señal de incertidumbre efectivamente ordena los ejemplos según su fiabilidad relativa. Aunque la escala del riesgo está condicionada por el fuerte desbalance del problema, la tendencia global es clara: automatizar menos y mejor permite reducir errores sobre el subconjunto retenido. Esta figura, por tanto, no solo respalda la intuición cualitativa de las figuras anteriores, sino que ofrece una justificación cuantitativa de la abstención selectiva.

Esta parte es una de las evidencias más fuertes del valor práctico del enfoque. Si una señal de incertidumbre es útil, debería permitir mejorar la calidad de las decisiones reteniendo únicamente los casos más fiables; y precisamente eso es lo que sugiere la curva cobertura-riesgo: cuanto más restrictivo es el sistema con la automatización, menor es el riesgo asumido sobre el subconjunto automatizado. Así, la incertidumbre puede interpretarse como una herramienta para regular de forma continua el compromiso entre volumen automatizado y seguridad.

Además, el hecho de que la incertidumbre aumente justamente en regiones ambiguas y en tipos de error problemáticos apoya la coherencia interna del enfoque. No se trata solo de que el modelo produzca una desviación estándar numérica, sino de que esa magnitud se alinea con casos donde intuitivamente esperaríamos menor fiabilidad. Esto refuerza la idea de que la BNN añade valor no por superar a los baselines en clasificación, sino por hacer visible qué parte del espacio de decisión debería tratarse con mayor cautela.

La Tabla 5 resume el coste computacional de los modelos en inferencia. El resultado importante no es únicamente que la BNN sea más lenta, sino por qué lo es: su estimación predictiva requiere muestreo Monte Carlo repetido, lo que eleva significativamente la latencia por muestra.

En otras palabras, el enriquecimiento probabilístico tiene un coste explícito. El uso de una BNN en este contexto solo se justifica si la mejora en control del riesgo compensa la penalización computacional. Usamos docker, streamlit para la demo web y una capa de monitorización con diferentes archivos que monitorizan las decisiones, incertidumbre y el riesgo residual en ACCEPT. Sin embargo, la monitorización es offline y no se ha implementado un sistema de producción online, lo que limita la generalización de los resultados a entornos reales.

Tabla 5: Eficiencia de inferencia y entrenamiento.

Modelo	Tamaño (MB)	Carga (s)	Inferencia total (s)	Latencia (μs/muestra)	Entrenamiento
Logistic Regression	0.004	0.001	0.041	0.7	1.3 s
XGBoost	0.586	0.080	0.073	1.3	3.4 s
Random Forest	7.508	0.235	0.180	3.2	33.6 s
BNN (+ prep.)	0.323	0.020	17.689	310.5	924 s

Consistencia de artefactos. Todos los umbrales de probabilidad, métricas de clasificación y reglas base del sistema se derivan directamente de los artefactos experimentales validados. En cambio, el umbral de incertidumbre τ_u reportado en la política final se fija mediante un análisis *post hoc* del compromiso entre cobertura automática y fraude residual en ACCEPT. Por tanto, los resultados de triaje deben interpretarse como un análisis operativo sobre la salida del modelo ya entrenado, no como un procedimiento de ajuste validado en un conjunto independiente.

5. Limitaciones y conclusión

Este trabajo presenta varias limitaciones importantes. Primero, la BNN no supera a los mejores modelos deterministas en ranking predictivo ni en calibración sobre este dataset tabular. Segundo, la incertidumbre usada por el sistema es una dispersión Monte Carlo de la posterior predictiva aproximada, no una descomposición formal entre incertidumbre aleatoria y epistémica. Tercero, la monitorización es offline y de tipo *snapshot*, no un sistema online de producción. Cuarto, aunque los tiempos de entrenamiento se han medido para caracterizar el coste computacional del sistema, el umbral de incertidumbre final se selecciona *post hoc* y no mediante un protocolo validado separado.

Aun así, la comparación entre modelos probabilísticos y deterministas en fraude debe formularse en dos planos distintos. En el plano predictivo, XGBoost y Random Forest son superiores a la BNN en las métricas más relevantes de discriminación y, en particular, los modelos de árbol presentan una calibración notablemente mejor. En ese sentido, este trabajo no proporciona evidencia de que una BNN sea el mejor clasificador tabular para este dataset.

Sin embargo, en el plano decisional la conclusión es distinta. La BNN permite construir una política de abstención explícita, identificar una fracción pequeña pero muy concentrada de operaciones de alto riesgo y, con el ajuste de τ_u, automatizar aproximadamente el 57 % del flujo manteniendo una tasa de fraude residual en ACCEPT del orden de 3×10^{-5}. La combinación de la Tabla 4, la Figura 1 y la Figura 7 sugiere precisamente eso: la incertidumbre estimada por el modelo no es solo un subproducto estadístico, sino una variable útil para gestionar el riesgo operativo.

La comparación final, por tanto, no es simplemente entre "mejor" y "peor" modelo. Si el objetivo fuese únicamente maximizar rendimiento predictivo offline, los modelos de árbol serían la opción natural. Si, en cambio, el objetivo incluye controlar mejor cuándo automatizar, cuándo derivar y cuándo aceptar el coste de una revisión humana, entonces la BNN ofrece una ventaja cualitativamente distinta. Ese es el trade-off central del trabajo: renunciar a parte del rendimiento puro a cambio de una señal explícita de incertidumbre que permite tomar decisiones más prudentes y más adaptadas al coste del error.

La conclusión principal no es que el modelo bayesiano sea globalmente mejor, sino que permite transformar una predicción binaria en una política de decisión más segura. En aplicaciones sensibles al riesgo, esa capacidad puede justificar su uso incluso cuando no domina en PR-AUC o NLL.

Referencias

[1] Charles Blundell, Julien Cornebise, Koray Kavukcuoglu, and Daan Wierstra. Weight uncertainty in neural networks. In *Proceedings of the 32nd International Conference on Machine Learning*, 2015.

[2] Andrea Dal Pozzolo, Olivier Caelen, Reid A. Johnson, and Gianluca Bontempi. Calibrating probability with undersampling for unbalanced classification. In *IEEE Symposium Series on Computational Intelligence*, 2015.

[3] Ran El-Yaniv and Yair Wiener. On the foundations of noise-free selective classification. *Journal of Machine Learning Research*, 11:1605–1641, 2010.

[4] Yarin Gal and Zoubin Ghahramani. Dropout as a Bayesian approximation: representing model uncertainty in deep learning. In *Proceedings of the 33rd International Conference on Machine Learning*, 2016.

[5] Tilmann Gneiting and Adrian E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007.

[6] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning*, 2017.

[7] Kaggle. Credit Card Fraud Detection. `https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud`, consultado el 17 de abril de 2026.

[8] Diederik P. Kingma and Max Welling. Auto-encoding variational Bayes. In *International Conference on Learning Representations*, 2014.

[9] Neil D. Lawrence. Probabilistic non-linear principal component analysis with Gaussian process latent variable models. *Journal of Machine Learning Research*, 6:1783–1816, 2005.

[10] Alexandru Niculescu-Mizil and Rich Caruana. Predicting good probabilities with supervised learning. In *Proceedings of the 22nd International Conference on Machine Learning*, 2005.

[11] Pyro Development Team. Automatic guide generation: `AutoDiagonalNormal`. `https://docs.pyro.ai/en/stable/infer.autoguide.html`, consultado el 17 de abril de 2026.

[12] Pyro Development Team. Stochastic variational inference in Pyro. `https://docs.pyro.ai/en/stable/inference_algos.html`, consultado el 17 de abril de 2026.

[13] Pyro Development Team. Predictive distribution in Pyro. `https://docs.pyro.ai/en/stable/_modules/pyro/infer/predictive.html`, consultado el 17 de abril de 2026.

A. Visualizaciones Adicionales

A.1. Espacio de Decisiones

De cara a ilustrar, más comprensiblemente, cómo se distribuyen las decisiones del sistema en función de los umbrales óptimos ($\tau^\star$ y τ_u), la Figura 5 muestra un diagrama de dispersión de las probabilidades predichas por el modelo frente a su incertidumbre, coloreado según la decisión final (ACCEPT, REVIEW, BLOCK):

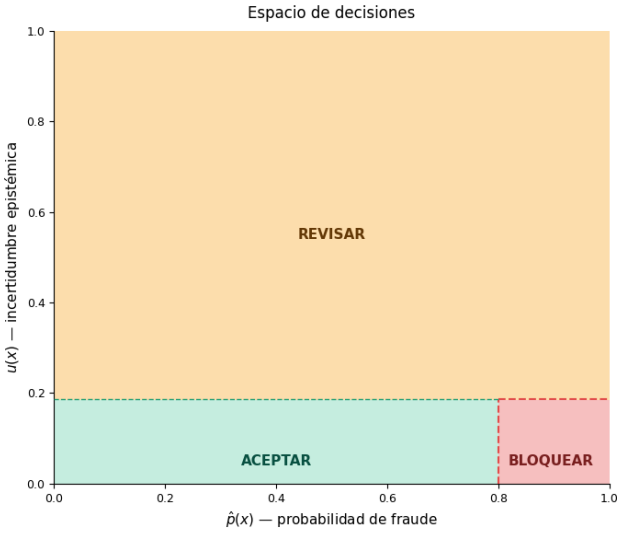

Figura 5: Espacio de decisiones (simplificado) del BNN. Medida de incertidumbre en el eje vertical, probabilidad predicha en el eje horizontal. Las líneas punteadas indican los umbrales de decisión para cada bucket.

Analizando la gráfica, podríamos caer en la tentación de concluir que el umbral de incertidumbre τ_u parece ser demasiado bajo (ya que su región, *Revisar*, comprende una gran proporción del área del cuadrado unitario). Sin embargo, es importante recordar que el umbral se selecciona en función de la tasa de fraude residual en ACCEPT, no simplemente por la distribución visual de los puntos. Por un lado, la distribución de transacciones en el espacio de decisiones no es uniforme, sino que se concentra en ciertas regiones (principalmente, cerca de probabilidades bajas). Por otro lado, el umbral de incertidumbre se ajusta para maximizar la automatización sin comprometer la seguridad, lo que implica aceptar una cierta cantidad de casos en REVIEW a cambio de reducir el riesgo en ACCEPT.

A.2. Incertidumbre por tipo de error

Para complementar la interpretación de la Figura 4, la Figura 6 muestra la distribución de incertidumbre para cada tipo de confusión (verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos). Esta visualización permite observar si los errores más problemáticos (especialmente los falsos negativos) tienden a concentrarse en niveles más altos de incertidumbre, lo que reforzaría la idea de que la señal de incertidumbre es útil para identificar casos donde el modelo es menos confiable.

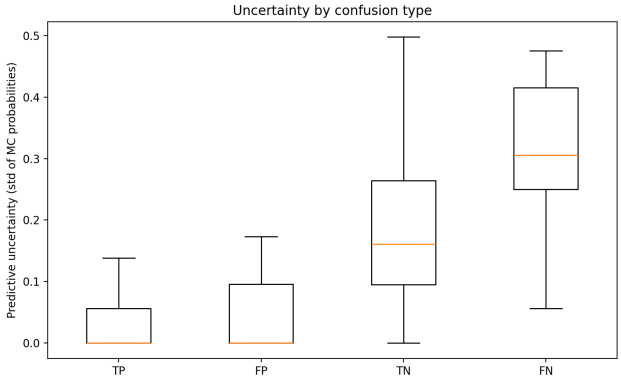

Figura 6: Incertidumbre por tipo de confusión.

A.3. Cobertura de riesgo

La Figura 7 muestra la curva de cobertura-riesgo del BNN, que ilustra cómo el riesgo empírico (tasa de fraude residual) disminuye a medida que se restringe la automatización a los casos con menor incertidumbre. Esta curva es fundamental para entender el trade-off entre volumen automatizado y seguridad, y para justificar cuantitativamente la utilidad de la señal de incertidumbre en la gestión operativa del riesgo.

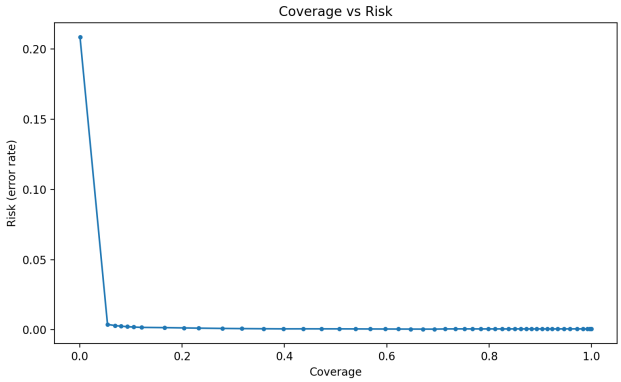

Figura 7: Curva cobertura-riesgo del BNN.

B. Explicación de las Métricas

Si bien, en el cuerpo del trabajo, asumimos que el lector está familiarizado con las métricas de clasificación, incluimos esta seción para proporcionar una explicación detallada de cada métrica utilizada, su interpretación y su relevancia para el caso de uso específico de detección de fraude.

B.1. PR-AUC (Área bajo la curva Precision-Recall)

La métrica PR-AUC mide el área bajo la curva que relaciona la precisión (precision) y la sensibilidad (recall) a medida que se varía el umbral de decisión. Resume la capacidad del modelo para identificar correctamente los casos positivos manteniendo una alta precisión, a lo largo de todo el rango de umbrales. Es especialmente relevante en problemas desbalanceados, como la detección de fraude, donde la clase positiva (fraude) es mucho menos frecuente que la clase negativa (no fraude):

$$\text{PR-AUC} = \int_0^1 \text{Precision}(r)\, dr,$$

donde r es el recall. Un valor de PR-AUC cercano a 1 indica que el modelo puede identificar la mayoría de los casos de fraude con alta precisión, mientras que un valor cercano a 0 indica un rendimiento pobre. Además, en clasificación binaria, una PR-AUC de 0.5 corresponde a un modelo que clasifica aleatoriamente.

Por lo tanto, puede ser más informativa que la ROC-AUC en este contexto, ya que esta última puede mantenerse constante incluso si el modelo tiene un rendimiento pobre en la clase minoritaria.

B.2. ROC-AUC (Área bajo la curva Receiver Operating Characteristic)

La métrica ROC-AUC mide el área bajo la curva que relaciona la tasa de verdaderos positivos (TPR, AKA recall) y la tasa de falsos positivos (FPR) a medida que se varía el umbral de decisión. Al aumentar la sensibilidad, el modelo tenderá a ser más optimista e introducir más falsos positivos, lo que se refleja en la curva ROC. Un valor de ROC-AUC cercano a 1 indica que el modelo tiene una excelente capacidad para distinguir entre las clases, mientras que un valor cercano a 0.5 indica un rendimiento aleatorio.

B.3. F1 Score

El F1 Score es la media armónica entre la precisión y el recall, y se calcula como:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

Esta métrica es útil para encontrar un equilibrio entre precisión y recall, especialmente en problemas desbalanceados. Un F1 Score alto indica que el modelo tiene tanto una alta precisión como un alto recall. En nuestro caso, nos indica cómo de fino es el equilibrio entre *evitar alarmas por transacciones legítimas* (precisión) y *no dejar pasar transacciones fraudulentas* (recall).

La principal limitación del F1 Score es que, en caso de ser un valor bajo, no indica si el problema es una baja precisión, un bajo recall o ambos. Por eso, es importante complementarlo con las métricas de precisión y recall por separado.

B.4. NLL (Negative Log-Likelihood)

El NLL mide la calidad de las probabilidades predichas por el modelo. Se calcula como:

$$\text{NLL} = -\frac{1}{N} \sum_{i=1}^{N} \left[y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right],$$

con y_i siendo la etiqueta verdadera (0 o 1) y $\hat{p}_i \in [0, 1]$ la probabilidad predicha de que la muestra i pertenezca a la clase positiva. De esta forma, el NLL no se limita a contar errores de clasificación, sino que tiene en cuenta la magnitud del error probabilístico. Un NLL bajo indica que el modelo asigna altas probabilidades a las clases correctas, mientras que un NLL alto indica que el modelo es menos confiable en sus predicciones.

B.5. Brier Score

El Brier Score es otra métrica de calidad probabilística que mide la media del error cuadrático entre las probabilidades predichas y las etiquetas verdaderas. Se calcula como:

$$\text{Brier} = \frac{1}{N}\sum_{i=1}^{N}(\hat{p}_i - y_i)^2.$$

Se puede entender Brier como una variante más suave del NLL. No penaliza tan severamente las predicciones extremas incorrectas, pero sigue siendo sensible a la calidad de las probabilidades. Un Brier Score bajo indica que el modelo es bueno asignando probabilidades cercanas a 0 o 1 para las clases correctas, mientras que un Brier Score alto indica que el modelo es menos confiable.

B.6. ECE (Expected Calibration Error)

El ECE mide la calibración del modelo, es decir, qué tan bien las probabilidades predichas reflejan la frecuencia real de los eventos. Se calcula agrupando las predicciones en bins según su probabilidad predicha y comparando la precisión dentro de cada bin con la probabilidad media del bin:

$$\text{ECE} = \sum_{m=1}^{M}\frac{|B_m|}{N}|\text{acc}(B_m) - \text{conf}(B_m)|,$$

donde B_m es el conjunto de muestras en el bin m, $\text{acc}(B_m)$ es la precisión observada en ese bin y $\text{conf}(B_m)$ es la probabilidad media predicha en ese bin. Un ECE bajo indica que el modelo está bien calibrado, mientras que un ECE alto indica que el modelo tiende a sobreestimar o subestimar la probabilidad de los eventos.

Es decir si el modelo tiene un ECE cercano al 0 %, podemo confiar en que las probabilidades predichas están alineadas con la frecuencia real de los eventos. Por ejemplo, entre las transacciones a las que el modelo asigna una probabilidad de fraude del 20 %, aproximadamente el 20 % de ellas serán realmente fraudulentas.